

Modelos de evaluación tipada y el colapso entre conflicto e ignorancia: un estudio de caso sobre Jev

Typed evaluation models and the collapse between conflict and ignorance: a case study on Jev

Maikel Yelandi Leyva Vázquez 1,2,3,*

1 Universidad Bernardo O'Higgins, Santiago, Chile.

2 Universidad Bolivariana del Ecuador, Guayaquil, Ecuador. E-mail: myleyvav@ube.edu.ec

3 Universidad de Guayaquil, Guayaquil, Ecuador. ORCID: <https://orcid.org/0000-0001-7911-5879>

* Autor de correspondencia: myleyvav@ube.edu.ec

Resumen. Los modelos de chat basados en LLM devuelven texto libre que debe interpretarse; una categoría de herramientas que emergió en septiembre de 2026, los modelos de evaluación tipada ("System One models"), devuelven en su lugar un objeto tipado directamente utilizable por software. Jev (TypeSafe AI, reportado por el fabricante como lanzado el 15 de septiembre de 2026) es el primer ejemplo comercial de esta categoría. Este trabajo lo ubica dentro de un panorama de cinco categorías de interacción con modelos de IA y examina, con un experimento mínimo, una predicción derivada de la teoría de decisión anotada: que una salida colapsada a una sola probabilidad calibrada no puede distinguir conflicto genuino de ignorancia genuina. Para el tipo de pregunta más simple de Jev (boolean/Noul), el experimento es consistente con esa predicción: los casos de conflicto (probabilidad 0,50-0,57) y de ignorancia (0,46-0,48) caen en la misma banda estrecha. Pero un segundo experimento, con el tipo Choice del mismo modelo y un esquema que nombra explícitamente "evidencia en conflicto" y "evidencia insuficiente" como opciones, separa ambos casos con probabilidad 1,0 en los cuatro casos completados. Un tercer experimento, con Choice restringido a las dos opciones originales (sin categorías de escape), no reproduce ni el colapso ni la separación perfecta: aparece un sesgo direccional no anticipado, posiblemente ligado a pistas léxicas del texto de entrada. El hallazgo central no es que Jev colapse per se, sino que el mismo modelo preserva, destruye, o distorsiona de forma no anticipada la distinción según el tipo de pregunta y el esquema declarado — un riesgo de diseño de interfaz más complejo de lo que un solo experimento de seguimiento podía anticipar.

Palabras clave: modelos de evaluación tipada; System One models; LLM-as-judge; lógica paraconsistente anotada; colapso representacional; abstención tipada; Jev.

Abstract. Chat-based LLMs return free text that must be interpreted; a category of tools that emerged in September 2026, typed evaluation models ("System One models"), instead return a typed object directly usable by software. Jev (TypeSafe AI, reported by the vendor as launched on September 15, 2026) is the first commercial example of this category. This work situates it within a five-category landscape of AI model interaction and tests, with a minimal experiment, a prediction derived from annotated decision theory: that an output collapsed to a single calibrated probability cannot distinguish genuine conflict from genuine ignorance. For Jev's simplest question type (boolean/Noul), the experiment is consistent with that prediction: conflict cases (probability 0.50-0.57) and ignorance cases (0.46-0.48) fall within the same narrow band. But a second experiment, using the same model's Choice type with a schema that explicitly names "conflicting evidence" and "insufficient evidence" as options, separates both cases with probability 1.0 in all four completed cases. A third experiment, with Choice restricted to the two original options (no escape categories), reproduces neither the collapse nor the clean separation: an unanticipated directional bias appears, possibly tied to lexical cues in the input text. The central finding is therefore not that Jev collapses per se, but that the same model preserves, destroys, or unpredictably distorts the distinction depending on the question type and declared schema — an interface design risk more complex than a single follow-up experiment could anticipate.

Keywords: typed evaluation models; System One models; LLM-as-judge; annotated paraconsistent logic; representational collapse; typed abstention; Jev.

1 Introducción

Un modelo de chat convencional, ante la pregunta "¿se aprobó el reembolso?", puede responder "Sí, parece que sí, aunque no estoy completamente seguro..." — una cadena de texto no estructurada que el software que la consume debe volver a parsear o interpretar, sin un score explícito ni una garantía de formato. Una categoría de herramientas que emergió en septiembre de 2026, los modelos de evaluación tipada, invierte esa relación: se le entrega al modelo un estado (el contexto o la evidencia disponible) y un esquema de preguntas, cada una con un tipo declarado, y el modelo devuelve, para cada pregunta, un valor en ese tipo junto con una probabilidad calibrada.

TypeSafe AI llama a su primer modelo de este tipo "System One" — la contraparte rápida e intuitiva del razonamiento lento y deliberado ("System Two") que persiguen los LLM de frontera [1]. Según el fabricante, Jev

no genera texto: selecciona entre las opciones de un esquema provisto por quien lo llama, por lo que devolver un valor mal formado o fuera del conjunto declarado sería estructuralmente imposible [2] — una garantía de formato, no una garantía de corrección del contenido. El fabricante reporta entre 20 y 200 veces más velocidad y hasta 400 veces menos costo que un LLM de frontera para esta clase de tareas [3], y un método de entrenamiento propio, Reinforcement Learning for Calibrated Decisions (RLCD), orientado a calibración explícita [4]. Ninguna de estas cifras fue auditada de forma independiente en este trabajo; se reportan como afirmaciones del fabricante, no como hechos verificados.

Este trabajo no evalúa el rendimiento de Jev en sus tareas previstas. Antes de examinarlo como caso de estudio (§3-§6), la §2 lo sitúa dentro de un panorama más amplio de categorías de interacción con modelos de IA. Luego se examina una pregunta de representación —¿qué pierde un modelo que colapsa evidencia a una sola probabilidad calibrada?— y, a partir de un hallazgo inesperado en el propio experimento, se refina esa pregunta hacia una más precisa: ¿la pérdida es del modelo, o del tipo de interfaz elegido para consultarlo?

2 Panorama de las categorías de interacción con modelos de IA

La oposición binaria "chat libre vs. tipado" simplifica demasiado el panorama real. La Figura 1 posiciona cinco categorías en dos ejes: costo computacional y rigidez/momento de fijación del esquema de decisión —no "flexibilidad de entrada", una formulación de una versión anterior de esta figura que inducía a una lectura errónea (sugería que el chat generativo era menos flexible que un modelo tipado, cuando es exactamente lo contrario en términos de qué se le puede preguntar). El eje correcto va de un esquema fijado en el entrenamiento (categoría 4, la más rígida) a un esquema declarado en cada llamada (categorías 2, 3 y 5) hasta la ausencia total de esquema (categoría 1, texto libre — la máxima libertad expresiva posible, pero con cero garantía estructural sobre la respuesta).

1. Modelos de chat generativos — texto libre, sin garantía de formato ni de tipo. Es el extremo sin esquema del eje: acepta cualquier pregunta, pero no ofrece ninguna garantía sobre la forma de la respuesta.

2. LLM con salida forzada (constrained decoding) — sigue siendo un modelo generativo de propósito general por debajo, pero en cada paso de generación se restringe el espacio de tokens válidos según una gramática o esquema JSON declarado [12]. El costo sigue siendo el de un LLM completo.

3. LLM-as-judge — un LLM de frontera o afinado evalúa según un criterio en lenguaje natural. Cuando se afina a una tarea específica, la literatura documenta que puede degenerar en un clasificador de dominio cerrado, con caída de rendimiento fuera de ese dominio [13].

4. Clasificadores discriminativos clásicos — arquitecturas no generativas dedicadas (p. ej. un BERT afinado, o una cabeza evidencial tipo EDL), deterministas, con esquema de clases fijado en el entrenamiento. Se reporta como sustancialmente más barato y rápido que un juez basado en LLM, aunque la cifra exacta varía según la fuente y no se toma aquí como dato preciso.

5. Jev y sus pares (modelos de evaluación tipada) — el caso de estudio de este trabajo.

Nota sobre esta taxonomía: no es una partición estricta. Las categorías 2 y 3 pueden superponerse en la práctica —un juez basado en LLM puede usar salida forzada para garantizar un veredicto en JSON válido— y se presentan como ejes heurísticos (uso, técnica de decodificación, arquitectura, costo) más que como clases mutuamente excluyentes. Es una síntesis propia de fuentes secundarias, no una revisión sistemática de la literatura de constrained decoding y LLM-as-judge.

Con esa salvedad, Jev se sitúa en la convergencia de las categorías 3 y 4: hereda de la 3 la flexibilidad de un esquema de preguntas declarado en tiempo de llamada, y de la 4 el costo bajo y la garantía de salida tipada por construcción. El ecosistema de evaluación de LLM converge hacia arquitecturas de dos niveles en 2026 —un clasificador barato que resuelve la mayoría de los casos y escala a un juez de frontera solo cuando el caso es ambiguo [14]— que es, estructuralmente, la misma cascada que una taxonomía de abstención tipada ya formaliza para la decisión bajo evidencia insuficiente o en disputa (síntesis propia del programa de investigación del autor, sin publicar; ver nota en §7).




Figura 1: Posicionamiento de las cinco categorías de interacción con modelos de IA según rigidez/momento de fijación del esquema (eje x: fijo en entrenamiento → declarado en cada llamada → sin esquema) y costo computacional (eje y). Jev se ubica en la convergencia entre el juez basado en LLM (categoría 3) y el clasificador discriminativo clásico (categoría 4); el chat generativo (categoría 1) ocupa el extremo sin esquema — máxima libertad expresiva, cero garantía estructural. Fuente: elaboración propia.

3 Taxonomía verificada de tipos en Jev

La documentación del fabricante [8] especifica tres primitivas de pregunta, evaluables en paralelo dentro de una misma llamada.

Tabla 1: Primitivas de pregunta soportadas por Jev.

Tipo	Qué hace	Qué devuelve
Choice	elegir una opción de un conjunto declarado (criterio: mapa opción→descripción)	opción elegida + probabilidad por cada opción
Score	puntuar el estado sobre una rúbrica de niveles ordenados	puntaje + probabilidad por cada nivel
Noul	pregunta de sí/no	la probabilidad de que la respuesta sea "sí"

Fuente: elaboración propia.

La documentación llama al tercer tipo "Noul", no "Boolean", y lo describe como una probabilidad continua en $[0,1]$ — no un valor discreto. El SDK de Vercel AI Gateway, que expone `experimental_evaluate` como interfaz de acceso, nombra ese mismo tipo boolean en su firma de API [9]. Verificado directamente contra el objeto de respuesta (§5): el campo `providerMetadata.typesafe.confidence` existe en el esquema pero llega vacío (`{}`) en los cinco casos ejecutados con el tipo boolean — no hay, en ese tipo, ningún campo adicional de confianza o composición de evidencia más allá de la probabilidad única.

4 La pregunta representacional

En el marco de lógica paraconsistente anotada (LPA2v) [10], un juicio se representa como un par independiente (μ, λ) . Dos vértices del retículo resultante, $\top$ (evidencia fuerte en ambos sentidos) y $\perp$ (ausencia de evidencia en cualquier sentido), son epistemológicamente opuestos pero comparten una propiedad geométrica: ambos están igual de lejos de los vértices "verdadero" y "falso" [11]. De ahí un resultado ya formalizado: todo score de cercanía a esos vértices es invariante bajo la involución que intercambia $\top$ y $\perp$ [11].

Este trabajo no aplica ese teorema de forma literal a Jev — hacerlo exigiría que Jev calculara explícitamente un par (μ, λ) independiente, cosa que no está documentada. La conexión es una analogía motivadora, no una consecuencia deductiva del teorema. El argumento que sí es deductivamente válido, y que este trabajo pone a prueba, es más simple: ningún mapa de un espacio de evidencia de dos o más dimensiones (apoyo, oposición, magnitud, insuficiencia) a un único escalar en $[0,1]$ puede ser inyectivo; dos estados de evidencia distintos pueden, por pura cardinalidad, colapsar al mismo número. Un modelo que solo expone ese escalar —como el tipo Noul de Jev— no puede, en principio, garantizar que conflicto e ignorancia produzcan valores distintos.

5 Método

Se diseñaron seis estados (state) en inglés sobre el mismo hecho de dominio (si un semáforo estaba en rojo), en cuatro categorías: TORN (conflicto genuino, $n=2$, dos fuentes igualmente confiables que se contradicen), SILENT (ignorancia genuina, $n=2$, ausencia documentada de evidencia), AGREE-SUPPORT (control, $n=1$, fuentes que concuerdan en "rojo") y AGREE-REFUTE (control, $n=1$, fuentes que concuerdan en "no rojo").

Experimento 1 (tipo boolean/Noul): una llamada por estado a typesafe-ai/jev vía experimental_evaluate del SDK ai v7.0.107, pregunta única: "Was the traffic light red at the time in question?"

Experimento 2 (tipo Choice, de seguimiento): los mismos seis estados, una sola pregunta lightState de tipo choice con cuatro opciones explícitas: red, green, conflicting_evidence ("reliable sources disagree with each other about the color") e insufficient_evidence ("there is no evidence available to determine the color"). Este segundo experimento se diseñó después de observar los resultados del Experimento 1, a partir de una revisión adversarial que señaló la necesidad de probar si el colapso era propio del modelo o del tipo de pregunta — se declara explícitamente como no preregistrado y motivado por los datos.

Experimento 3 (Choice binario, cierre de la pregunta abierta): los mismos seis estados, la misma pregunta lightState de tipo choice, pero con solo las dos opciones originales: red y green, sin categorías de escape. Prueba si la separación perfecta del Experimento 2 depende de que el esquema pueda nombrar conflicto/insuficiencia, o si es una propiedad general del tipo Choice independiente del esquema. También motivado por los datos, no pre-registrado.

Ninguno de los tres experimentos promedia repeticiones (una sola llamada por caso; limitación en §8). Las llamadas se hicieron el 19 de septiembre de 2026 contra el modelo en producción, sin acceso a sus pesos ni a su conjunto de entrenamiento.

6 Resultados

Tabla 2: Experimento 1 (tipo boolean/Noul) — probabilidad de "rojo".

Caso	Categoría	P(rojo)
TORN-1	conflicto genuino (testigos contradictorios)	0,57
TORN-2	conflicto genuino (sensores contradictorios)	0,50
SILENT-1	ignorancia genuina (sin testigos ni cámaras)	0,46
SILENT-2	ignorancia genuina (registro perdido)	0,48
AGREE-SUPPORT	control: fuentes de acuerdo (apoyo)	0,83
AGREE-REFUTE	control: fuentes de acuerdo (refutación)	sin datos (rate-limit, §8)

Fuente: elaboración propia.

Los dos casos TORN (0,50–0,57) y los dos SILENT (0,46–0,48) caen en una banda común y estrecha. El único control completado con evidencia inequívoca (AGREE-SUPPORT) produce 0,83, alejado de 0,5.

Tabla 3: Experimento 2 (tipo Choice, esquema enriquecido) — elección y probabilidad.

Caso	Categoría	Elección de Jev	P(elección)
TORN-1	conflicto genuino	conflicting_evidence	1,00
TORN-2	conflicto genuino	conflicting_evidence	1,00
SILENT-1	ignorancia genuina	insufficient_evidence	1,00
SILENT-2	ignorancia genuina	insufficient_evidence	1,00
AGREE-SUPPORT	control: fuentes de acuerdo	red	1,00
AGREE-REFUTE	control: fuentes de acuerdo	sin datos (rate-limit, §8)	—

Fuente: elaboración propia.

Con el tipo Choice y un esquema que nombra explícitamente "evidencia en conflicto" y "evidencia insuficiente" como opciones de primera clase, Jev separa los cuatro casos experimentales (TORN vs. SILENT) con probabilidad máxima y sin ambigüedad, y clasifica correctamente el control de apoyo. La misma evidencia tex-

tual que colapsó a una banda de 0,46–0,57 bajo el tipo boolean produce una distinción perfecta bajo el tipo Choice.

Tabla 4: Experimento 3 (tipo Choice binario, red/green sin categorías de escape).

Caso	Categoría	P(red)	P(green)
TORN-1	conflicto genuino	0,85	0,15
TORN-2	conflicto genuino	0,84	0,16
SILENT-1	ignorancia genuina	0,67	0,33
SILENT-2	ignorancia genuina	0,77	0,23
AGREE-SUPPORT	control: fuentes de acuerdo	1,00	0,00
AGREE-REFUTE	control: fuentes de acuerdo	sin datos (rate-limit, §8)	—

Fuente: elaboración propia.

Sin categorías de escape, Jev no reproduce el colapso a ~0,5 del Experimento 1 ni la separación perfecta del Experimento 2. Aparece, en cambio, un sesgo direccional hacia red en los seis casos, más marcado en TORN (0,84–0,85) que en SILENT (0,67–0,77) — una tendencia ordinal débil ($n=2$ por categoría) que no permite una conclusión firme. Es un tercer patrón, no anticipado por ninguna de las dos hipótesis simples (colapso simétrico o separación limpia).

7 Discusión

El patrón del Experimento 1 es consistente con la predicción de la §4: bajo el tipo Noul, Jev no distingue por qué la evidencia no es clara. Pero el Experimento 2 obliga a corregir la interpretación: la pérdida no es una propiedad del modelo Jev, sino del tipo de pregunta y del esquema declarados para consultarlo. El tipo boolean fuerza, por definición, una salida en un espacio de un solo grado de libertad — no hay forma de que devuelva "conflicto" o "insuficiencia" aunque internamente el modelo los distinga. El tipo Choice, cuando el esquema incluye esas categorías como opciones nombradas, sí tiene espacio representacional para expresarlas, y el modelo lo aprovecha con una nitidez que no se anticipaba (probabilidad 1,0, no una tendencia difusa).

Esto reencuadra la contribución del trabajo: no es "Jev tiene una limitación representacional inherente", sino que el diseño del esquema de consulta determina si la distinción sobrevive, y el tipo más simple y barato de usar (Noul, una sola pregunta de sí/no) es precisamente el que la destruye por construcción. Es un riesgo de uso, no un defecto de ingeniería del producto.

El Experimento 3 responde la pregunta abierta de la v0.2 solo parcialmente, y de una forma más incómoda que cualquiera de las dos respuestas simples que se anticipaban. La hipótesis "Choice separa siempre, sea cual sea el esquema" queda descartada: sin categorías de escape, no hay separación limpia (0,84 no es 1,00, y SILENT no se acerca a 0,5 por el lado contrario). Pero la hipótesis alternativa "sin escape, Choice colapsa igual que Noul" también queda descartada: no hay un colapso simétrico hacia 0,5 en ningún caso — todos los valores, incluidos los SILENT sin evidencia alguna, se inclinan hacia red.

La explicación más honesta disponible con estos datos, sin sobreinterpretar un $n=2$ por celda, es un posible confusor léxico en el diseño del propio estímulo: los estados TORN y AGREE-SUPPORT contienen literalmente la palabra "red" en el texto (alguien la afirma, aunque sea contestada), mientras que los estados SILENT no mencionan ni "red" ni "green" en absoluto. Si el modelo pondera en parte la presencia superficial de la palabra que nombra una opción —y no solo si esa afirmación es creíble o está en disputa—, eso produciría exactamente el patrón observado. Esta explicación es plausible y verificable, pero este trabajo no la probó de forma controlada — queda como pregunta abierta genuina, no como hallazgo cerrado.

Lo que sí se sostiene con los tres experimentos juntos: el argumento deductivo de la §4 (ningún escalar único puede ser inyectivo sobre un espacio de evidencia de mayor dimensión) explica el colapso del tipo Noul, pero no predice ni explica el patrón del Experimento 3 — un Choice con dos opciones no es un escalar único inyectivo de la misma manera, y aun así no logró la separación que su espacio representacional permitiría en principio. La recomendación práctica se mantiene, pero se vuelve más cautelosa: para preservar la distinción entre conflicto e ignorancia, no basta con evitar el tipo boolean — hace falta, además, que el esquema de Choice nombre esos estados explícitamente, y conviene verificar empíricamente que el modelo no esté respondiendo a pistas léxicas superficiales del estado en vez de a la estructura real de la evidencia.

8 Limitaciones

(a) $n=5$ casos completados de 6 en cada uno de los tres experimentos (el control AGREE-REFUTE falló por límite de tasa del nivel gratuito de Vercel AI Gateway en los tres, incluso con un método de pago ya registrado — el proveedor exige créditos de pago cargados, no solo una tarjeta en archivo, y ese paso no se completó; es el único caso que nunca se pudo observar, en ninguna condición); (b) una sola llamada por caso en cada experimento, sin repetición para estimar varianza — crítico para el Experimento 3, cuyo patrón ($n=2$ por categoría) no permite distinguir tendencia real de ruido de muestra; (c) los Experimentos 2 y 3 fueron motivados por resultados previos y no estaban preregistrados — se declara así explícitamente; (d) la explicación del sesgo léxico en el

Experimento 3 (§7) es plausible pero no se probó de forma controlada; (e) es un producto de cuatro días de antigüedad al momento de escribir esto — su comportamiento y límites pueden cambiar sin aviso, y estos resultados son una fotografía del 19-sep-2026; (f) las cifras de velocidad, costo y método de entrenamiento (RLCD) son afirmaciones del fabricante, no auditadas de forma independiente en este trabajo; (g) la taxonomía de cinco categorías de la §2 es síntesis propia, no revisión sistemática.

9 Conclusión

El primer experimento de este trabajo pareció confirmar que los modelos de evaluación tipada heredan, por diseño representacional, el colapso entre conflicto e ignorancia ya caracterizado en la teoría de decisión anotada. Un segundo experimento mostró que esa conclusión era incompleta: el mismo modelo, con un esquema Choice que nombra explícitamente los estados epistémicos en disputa, separa conflicto de ignorancia con probabilidad máxima. Un tercer experimento, diseñado para aislar si esa separación dependía del esquema o del tipo de pregunta, mostró que la realidad es más desordenada que cualquiera de esas dos historias: sin categorías de escape, Jev no colapsa simétricamente ni separa limpiamente, sino que exhibe un sesgo direccional no anticipado, posiblemente ligado a pistas léxicas superficiales del texto de entrada.

La lección que sobrevive a los tres experimentos no es sobre un límite fijo de Jev como producto, sino sobre dos riesgos distintos y ambos reales para quien construya sobre modelos de evaluación tipada: primero, reducir una decisión epistémicamente compleja al tipo de interfaz más simple disponible (boolean/Noul) descarta información por construcción; segundo, incluso una interfaz más expresiva (Choice) puede fallar de formas no obvias —sesgadas, no simplemente "menos informativas"— cuando el esquema no nombra explícitamente los estados que importan.

Conflicto de intereses

El autor declara no tener ningún conflicto de intereses.

Disponibilidad de datos y código

Repositorio público: <https://github.com/mleyvaz/jev-typed-evaluation-collapse> — incluye el script y resultados del Experimento 1 (run_experiment.mjs, results.json), del Experimento 2 (run_experiment_choice.mjs, results_choice.json), del Experimento 3 (run_experiment_choice_binary.mjs, results_choice_binary.json), el script de la Figura 1 (make_fig1_taxonomy.py), y la ronda de revisión adversarial que motivó las revisiones v0.1 → v0.2 → v0.3.

Referencias

- [1] TypeSafe AI. Introducing System One Models & Jev. TypeSafe AI Blog, 15-sep-2026.
- [2] DataCamp. Jev: TypeSafe's System One Model That Never Hallucinates. datacamp.com/blog/system-one-models-jev
- [3] Vercel. TypeSafe AI's Jev now available on AI Gateway. Vercel Changelog.
- [4] explainx.ai. How Does Jev Work? RLCD & Parallel Inference Explained. 2026.
- [5] Mapika. decider: One-pass typed decisions with calibrated probabilities, fine-tuned from Qwen3.5-2B. GitHub.
- [6] nateGeorge. reflex: A small open decision model — a Jev / System One re-creation on Qwen3.5. GitHub.
- [7] Eliot, L. New 'Reinforcement Learning For Calibrated Decisions' Makes AI Headlines But Look Past The Hype. Forbes, 18-sep-2026.
- [8] TypeSafe AI. Introduction — Question Types. docs.typesafe.ai/introduction
- [9] Vercel. Jev API, Pricing & Playground. AI Gateway Models.
- [10] da Costa, N.C.A., Abe, J.M., Subrahmanian, V.S. (1991). Remarks on annotated logic. *Zeitschrift für Mathematische Logik und Grundlagen der Mathematik*, 37.
- [11] Leyva-Vázquez, M. (2026). Conflation-Invariant TOPSIS Scores and Panel-Level Abstention in Annotated Evidence [manuscrito en preparación]. Preprint SSRN 7441661.
- [12] Park, K., Zhou, T., D'Antoni, L. (2025). Flexible and Efficient Grammar-Constrained Decoding. arXiv:2502.05111. También en ICML 2025.
- [13] Huang, H., Bu, X., Zhou, H., Qu, Y., Liu, J., Yang, M., Xu, B., Zhao, T. (2024). An Empirical Study of LLM-as-a-Judge for LLM Evaluation: Fine-tuned Judge Model is not a General Substitute for GPT-4. arXiv:2403.02839. Findings of ACL 2025.
- [14] Gu, J., Jiang, X., Shi, Z., Tian, H., Zhai, X., Xu, C., et al. (2026). A survey on LLM-as-a-judge. *The Innovation*, 7(6), 101253.

Received: September 19, 2026. Accepted: —

Anexo A. Estados de entrada (verbatim)

Los seis estados (state) usados en los tres experimentos, idénticos en cada uno — solo cambia la pregunta (questions) que se declara sobre ellos.

TORN-1 (conflicto genuino)

Witness A, a police officer with a clear view of the intersection, testified under oath that the traffic light was red at the moment of the collision. Witness B, a bystander standing next to Witness A with an equally clear view, testified under oath that the same traffic light was green at that exact moment. Both witnesses are considered reliable by the investigating officer; there is no indication either one is lying.

TORN-2 (conflicto genuino)

Sensor 1, a calibrated high-precision traffic sensor, recorded the light as RED at 14:03:02. Sensor 2, an equally calibrated high-precision sensor mounted on the same pole, recorded the light as GREEN at the same timestamp, 14:03:02. Both sensors passed their most recent calibration check with no faults reported.

SILENT-1 (ignorancia genuina)

No witnesses were present at the intersection at the time in question. No traffic cameras were operating in that area that day. There is no record, sensor log, or testimony of any kind describing the state of the traffic light at that moment.

SILENT-2 (ignorancia genuina)

The traffic light's camera log for that day was permanently lost in a server failure before any backup was made. No witnesses have come forward. No other observation of the light exists in any form.

AGREE-SUPPORT (control, apoyo)

Witness A testified that the traffic light was red at the time of the collision. Witness B, standing nearby with an independent line of sight, separately and independently confirmed that the light was red at that same moment.

AGREE-REFUTE (control, refutación)

Witness A testified that the traffic light was green, not red, at the time of the collision. Witness B, standing nearby with an independent line of sight, separately and independently confirmed that the light was green at that same moment.

Anexo B. Código de la llamada, por experimento

Experimento 1 (boolean/Noul):

```
import { experimental_evaluate as evaluate } from 'ai';

const result = await evaluate({
  model: 'typesafe-ai/jev',
  state: STATE_TEXT, // uno de los seis estados del Anexo A
  questions: {
    wasRed: {
      type: 'boolean',
      instructions: 'Was the traffic light red at the time in question?',
    },
  },
});
```

Experimento 2 (Choice, esquema enriquecido):

```
const result = await evaluate({
  model: 'typesafe-ai/jev',
  state: STATE_TEXT,
  questions: {
    lightState: {
      type: 'choice',
      instructions: 'What was the state of the traffic light at the time in question?',
      criteria: {
        red: 'The evidence indicates the light was red.',
        green: 'The evidence indicates the light was green (not red).',
        conflicting_evidence: 'Reliable sources disagree with each other about the color.',
        insufficient_evidence: 'There is no evidence available to determine the color.',
      },
    },
  },
});
```

Experimento 3 (Choice binario, sin categorías de escape):

```
const result = await evaluate({
  model: 'typesafe-ai/jev',
  state: STATE_TEXT,
  questions: {
    lightState: {
      type: 'choice',
      instructions: 'What was the state of the traffic light at the time in question?',
```

```

criteria: {
  red: 'The evidence indicates the light was red.',
  green: 'The evidence indicates the light was green (not red).',
},
},
});

```

Anexo C. Respuesta completa (answers) por caso

Objeto answers devuelto por Jev para cada caso completado, sin editar (el objeto completo de respuesta incluye además usage, warnings, rounding y providerMetadata, disponibles en los archivos results*.json del repositorio).

Experimento 1 — boolean/Noul:

```

TORN-1:      {"wasRed":{"type":"boolean","probability":0.57}}
TORN-2:      {"wasRed":{"type":"boolean","probability":0.50}}
SILENT-1:    {"wasRed":{"type":"boolean","probability":0.46}}
SILENT-2:    {"wasRed":{"type":"boolean","probability":0.48}}
AGREE-SUPPORT: {"wasRed":{"type":"boolean","probability":0.83}}
AGREE-REFUTE: ERROR - GatewayRateLimitError (rate-limit del nivel gratuito, S8)

```

Experimento 2 — Choice enriquecido:

```

TORN-1:      {"lightState":{"choice":"conflicting_evidence","probabilities":
               {"red":0,"green":0,"conflicting_evidence":1,"insufficient_evidence":0}}}
TORN-2:      {"lightState":{"choice":"conflicting_evidence","probabilities":
               {"red":0,"green":0,"conflicting_evidence":1,"insufficient_evidence":0}}}
SILENT-1:    {"lightState":{"choice":"insufficient_evidence","probabilities":
               {"red":0,"green":0,"conflicting_evidence":0,"insufficient_evidence":1}}}
SILENT-2:    {"lightState":{"choice":"insufficient_evidence","probabilities":
               {"red":0,"green":0,"conflicting_evidence":0,"insufficient_evidence":1}}}
AGREE-SUPPORT: {"lightState":{"choice":"red","probabilities":
               {"red":1,"green":0,"conflicting_evidence":0,"insufficient_evidence":0}}}
AGREE-REFUTE: ERROR - GatewayRateLimitError (rate-limit del nivel gratuito, S8)

```

Experimento 3 — Choice binario:

```

TORN-1:      {"lightState":{"choice":"red","probabilities":{"red":0.85,"green":0.15}}}
TORN-2:      {"lightState":{"choice":"red","probabilities":{"red":0.84,"green":0.16}}}
SILENT-1:    {"lightState":{"choice":"red","probabilities":{"red":0.67,"green":0.33}}}
SILENT-2:    {"lightState":{"choice":"red","probabilities":{"red":0.77,"green":0.23}}}
AGREE-SUPPORT: {"lightState":{"choice":"red","probabilities":{"red":1,"green":0}}}
AGREE-REFUTE: ERROR - GatewayRateLimitError (rate-limit del nivel gratuito, S8)

```